



المدرسة العليا
للتكنولوجيا - الصويرة
L'ÉCOLE SUPÉRIEURE DE
TECHNOLOGIE – ESSAOUIRA

Département : Mathématiques-informatique

Filière : Informatique Décisionnelle et Sciences de données

Rapport du Projet de Fin d'Études :

Application Web de Diagnostic Médical assisté par le Machine Learning

Réalisé par :

Salah Eddine Boudans

Imane Idhaddou

Encadré par :

Mr. Youssef Taouil

Année universitaire : 2023-2024

Dédicace

Chers Parents Bien-Aimés,

Peu importe nos actions ou nos paroles, il nous semble impossible de vous exprimer toute notre gratitude comme il se doit. Votre amour nous entoure, votre soutien éclaire notre chemin et votre présence à nos côtés a toujours été notre rocher dans la tempête, nous permettant de surmonter les obstacles qui se dressent sur notre chemin.

C'est grâce à vos encouragements que nous avons embrassé cette voie, et grâce à vos critiques constructives que nous avons pu nous élever et nous améliorer.

Nous espérons que notre travail sera un humble témoignage de l'amour profond et de la reconnaissance que nous portons envers les sacrifices que vous avez consentis pour nous.

Nous tenons également à dédier ce travail à toutes les personnes qui ont contribué à notre formation : nos formateurs, dont la patience et les sacrifices ont été inestimables, et nos collègues, avec qui nous partageons connaissances et expériences.

Enfin, nous adressons nos salutations respectueuses à vous, chers lecteurs, qui nous accordez votre temps et votre attention.

Cordialement.

Remerciements

Tout d'abord, nous exprimons notre profonde gratitude envers Dieu, qui nous a guidés et affermis avec la patience et le courage nécessaires tout au long de notre parcours académique. Nous souhaitons également exprimer notre reconnaissance à toutes les personnes qui ont contribué de près ou de loin, de diverses manières, à la réussite de ce projet.

Nous tenons à adresser nos sincères remerciements à notre superviseur, **Monsieur Youssef Taouil**, pour son accompagnement infailible tout au long de notre travail. Sa disponibilité, sa patience, ses conseils avisés et ses remarques pertinentes ont été d'une aide précieuse, et nous lui en sommes infiniment reconnaissants.

Enfin, nous voulons exprimer nos plus sincères remerciements à tous nos amis et notre famille, dont le soutien indéfectible et les encouragements constants ont été un pilier essentiel tout au long de cette entreprise.

Résumé

Ce projet vise à concevoir et développer un système web permettant aux utilisateurs de saisir leurs indicateurs de santé, d'uploader des images médicales, et de recevoir des prédictions de risque pour les maladies telles que le diabète, les maladies cardiaques et la pneumonie.

Ces prédictions sont générées par un modèle de machine Learning intégré à la plateforme. Une authentification sécurisée des utilisateurs est mise en place pour garantir la confidentialité des données médicales. Ce projet inclut également l'option de communiquer avec un Chatbot médical.

Abstract

This project aims to design and develop a web system allowing users to input their health indicators, upload medical images, and receive risk predictions for diseases such as diabetes, heart diseases, and pneumonia.

These predictions are generated by a machine learning model integrated into the platform. Secure user authentication is implemented to ensure the confidentiality of medical data. This project also includes the option to communicate with a medical Chatbot.

Table des matières

Introduction générale	1
Chapitre 1 : Contexte générale et objectifs du projet.....	2
I. Contexte du domaine	2
1. Data Science :	2
2. Les composants de la science des données :	2
3. Intelligence Artificielle :	2
4. Machine Learning :	3
5. NLP :	4
6. Deep learning:	5
II. Énoncé du problématique et solution suggérée	6
1. Problématique :	6
2. Solution proposée :	6
3. Défis à surmonter :	7
4. Réponse du projet :	7
Chapitre 2 : Modélisation et Conception technique du projet	8
I. Introduction.....	8
II. Modélisation UML :	8
1. Diagramme des cas d'utilisation :	8
2. Diagramme de séquences :	9
III. Schéma Générale du projet :	11
IV. Les modèles utilisés :	11
1.Modèle séquentiel :	11
1.1 Modèle Séquentiel pour la Prédiction du Diabète :	12
1.2 Evaluation du modèle :	13
1.3 Modèle Séquentiel pour la Prédiction des Maladies Cardiovasculaires :	13
1.4 Evaluation du modèle :	13
1.5 Comparaison des modèles :	14
1.6 Augmentation de notre Dataset pour une amélioration des modèles :	15
2. Modèle VGG16 :	15
2.1 Structure VGG16 :	16
2.2 Modèle VGG16 pour la prédiction de la Pneumonie :	17
3. Le Chatbot médical :	19
3.1 Fonctionnement.....	19
3.2 Comment on a utilisé NLP ?	21
4. Conclusion	22

Chapitre 3 : Technologies Utilisées	23
I. Introduction.....	23
II. Les langages et les outils utilisés.....	23
Chapitre 4 : Implémentation du Projet.....	26
Conclusion Générale	33
Références Bibliographiques.....	34

Liste des figures

Figure 1 : Schéma représentatif de AI	3
Figure 2 : Etapes du Machine Learning	4
Figure 3: NLP (Natural Language Processing)	5
Figure 4 : Schéma du réseaux de neurones	5
Figure 5 : Diagramme de cas d'utilisation pour le patient	9
Figure 6 : Diagramme de séquences	10
Figure 7 : Schéma représentatif du projet	11
Figure 8 : Schéma du Modèle séquentiel	12
Figure 9 : Evaluation de prédiction du diabète	13
Figure 10 : Evaluation de prédiction du diabète	14
Figure 11 : Architecture VGG16	16
Figure 12 : Evaluation du modèle VGG16	19
Figure 13 : Exemple d'entraînement d'un message textuel	20
Figure 14 : L'architecture du modèle de réseaux de neurones à propagation avant .	20
Figure 15 : Exemple de Tokenization	21
Figure 16 : Exemple de Stemming	21
Figure 17 : Traitement d'un message avant de le représenter sous forme de vecteurs Bag of Words	22
Figure 18 : Page d'accueil / Partie 1	26
Figure 19 : Page d'accueil / Partie 2	27
Figure 20 : Page d'authentification	27
Figure 21 : Page de connexion	28
Figure 22 : Oubli de Mot de Passe	28
Figure 23 : Changement de mot de passe	29
Figure 24 : Page de Prédiction du diabète	29
Figure 25 : Résultat de Prédiction	30
Figure 26 : Page de Prédiction de Pneumonie	30
Figure 27 : Résultat de prédiction	30
Figure 28 : Page de Prediction Heart-Disease	31
Figure 29 : Résultat de Prédiction	31
Figure 30 : Chatbot	32

Liste des tableaux

Tableau I : Comparaison des modèles pour la prédiction du diabète	14
Tableau II : Comparaison des modèles pour la prédiction des maladies cardio	14

Introduction générale

Ce rapport présente le fruit d'un projet de site web dédié à la prédiction des maladies, réalisé dans le cadre de notre projet de fin d'études en Informatique Décisionnelle et Sciences de Données (IDSD) à l'École Supérieure de Technologies d'Essaouira. Ce projet a été entrepris dans le but de répondre à un besoin croissant de solutions innovantes dans le domaine de la santé.

Face à l'évolution constante de la médecine et l'importance croissante des données dans le secteur de la santé, les sciences de données jouent un rôle central en permettant d'analyser et de tirer des prédictions à partir de vastes ensembles de données médicales. Dans ce contexte, ce projet propose une approche novatrice en combinant la prédiction des maladies avec l'utilisation d'un Chatbot pour fournir des réponses aux questions des utilisateurs.

Notre plateforme web utilise des techniques avancées d'apprentissage automatique pour analyser les données médicales historiques et en temps réel, afin de prédire les maladies avec précision. Le Chatbot intégré fournit une interface conviviale permettant aux utilisateurs de poser des questions et d'obtenir des réponses instantanées.

Nous souhaitons que ce rapport serve de source d'inspiration pour d'autres projets dans le domaine de la santé numérique et encourage le développement de solutions innovantes pour répondre aux défis actuels de la médecine et de la santé publique.

Chapitre 1 : Contexte générale et objectifs du projet

I. Contexte du domaine

1. Data Science :

La Data Science est l'étude de la collecte, de l'analyse et de l'interprétation de données pour résoudre des problèmes complexes. Elle comprend des techniques telles que l'exploration de données, la modélisation statistique, l'apprentissage automatique et l'analyse prédictive. Dans notre projet, la Data Science est utilisée pour développer **des modèles de prédiction de maladies** en analysant les données de santé des utilisateurs.

2. Les composants de la science des données :

La science des données est composée de plusieurs éléments clés, notamment :

- **La collecte de données** : Acquisition de données à partir de diverses sources telles que des bases de données, des capteurs, des fichiers CSV, etc.
- **Le nettoyage des données** : Processus de filtrage et de préparation des données pour éliminer les valeurs aberrantes, les données manquantes et les erreurs.
- **L'exploration des données** : Analyse exploratoire des données pour découvrir des tendances, des relations et des modèles.
- **La modélisation des données** : Création de modèles statistiques ou prédictifs à partir des données.
- **La visualisation des données** : Représentation des données pour une compréhension plus claire et une communication efficace des résultats.

3. Intelligence Artificielle :

L'intelligence artificielle (IA) est un domaine de l'informatique qui vise à créer des systèmes capables de simuler l'intelligence humaine. Dans notre projet, l'IA est utilisée pour développer des modèles de Machine Learning capables de prédire le risque de maladies à partir des données de santé des utilisateurs. Ces modèles utilisent des algorithmes d'apprentissage automatique pour analyser les données et fournir des prédictions précises.




Figure 1 : Schéma représentatif de AI

4. Machine Learning :

Le Machine Learning est un domaine complexe qui peut prendre du temps à comprendre en profondeur. Pour simplifier, on peut dire que c'est une branche de l'intelligence artificielle où les programmes informatiques apprennent à partir des données fournies. Il existe quatre principales approches d'apprentissage :

1. **L'apprentissage supervisé** : Dans ce cas, les données sont étiquetées, permettant à l'algorithme de reconnaître des schémas spécifiques.
2. **L'apprentissage non supervisé** : Ici, les données ne sont pas étiquetées, et l'algorithme cherche à découvrir des structures ou des relations entre les données.
3. **L'apprentissage semi-supervisé** : Il s'agit d'une combinaison des deux approches précédentes, où une partie des données est étiquetée tandis que l'autre ne l'est pas.
4. **L'apprentissage par renforcement** : Dans ce type d'apprentissage, l'algorithme apprend en interagissant avec son environnement, recevant des récompenses pour ses actions positives.




Figure 2 : Etapes du Machine Learning

5. NLP :

Le traitement du langage naturel (NLP), également appelé traitement automatique du langage naturel (TALN), désigne la branche de l'informatique et plus spécifiquement de l'intelligence artificielle (IA) qui se préoccupe de donner aux ordinateurs la capacité de comprendre le texte et les mots parlés de la même manière que les êtres humains.




Figure 3: NLP (Natural Language Processing)

6. Deep learning:

Le Deep Learning, est une technique d'apprentissage automatique basée sur des réseaux de neurones artificiels à plusieurs couches. Ces réseaux sont capables d'apprendre des représentations de données de haut niveau à partir de données brutes. Dans notre projet, l'apprentissage en profondeur est utilisé pour développer des modèles de prédiction de maladies à partir de données médicales complexes et volumineuses.




Figure 4 : Schéma du réseaux de neurones

En résumé, la Data Science, l'intelligence artificielle, l'apprentissage automatique et l'apprentissage en profondeur jouent tous un rôle crucial dans notre projet en permettant le développement de modèles de prédiction de maladies à partir des données de santé des utilisateurs. Ces techniques nous permettent d'analyser efficacement les données, de découvrir des motifs et des tendances, et de fournir des prédictions précises pour améliorer la prise de décision en matière de santé.

II. Énoncé du problème et solution suggérée

1. Problématique :

Le domaine de la santé est confronté à plusieurs défis, notamment la nécessité d'une surveillance régulière de la santé, la prévention des maladies et la prise de décisions médicales précoces. Cependant, les méthodes traditionnelles de diagnostic et de suivi de la santé peuvent être coûteuses, laborieuses et parfois inaccessibles pour certaines populations. De plus, il existe souvent un manque de personnalisation dans les conseils de santé.

2. Solution proposée :

Pour répondre à ces défis, notre projet vise à développer un système innovant de diagnostic médical assisté par le machine Learning. Ce système offre plusieurs fonctionnalités clés pour améliorer la surveillance de la santé et la prévention des maladies :

- **Système d'authentification sécurisé pour les patients :**

Assurer la confidentialité des données médicales des utilisateurs en mettant en place un système d'authentification robuste.

- **Saisie d'indicateurs de santé et d'images médicales :**

Permettre aux utilisateurs de saisir facilement leurs indicateurs de santé, ainsi que d'uploader des images médicales (radiographie).

- **Modèles de Machine Learning pour la prédiction de maladies :**

Développer des modèles de Machine Learning capables de prédire le risque de différentes maladies, telles que le diabète, les maladies cardiaques et la pneumonie, en analysant les données de santé des utilisateurs.

- **Intégration d'un Chatbot pour la communication :**

Ajouter une fonctionnalité de Chatbot qui peut répondre aux questions des utilisateurs.

3. Défis à surmonter :

- **Collecte et gestion des données** : Il est crucial de collecter et de gérer efficacement les données de santé des utilisateurs tout en garantissant leur confidentialité et leur sécurité.
- **Précision des modèles de prédiction** : Les modèles de Machine Learning doivent être précis et fiables dans leurs prédictions pour garantir une prise de décision médicale appropriée.
- **Interface utilisateur conviviale** : L'interface utilisateur doit être simple pour permettre aux utilisateurs de saisir facilement leurs données de santé et d'obtenir des résultats clairs.

4. Réponse du projet :

Pour surmonter ces défis, notre projet s'appuie sur une infrastructure web solide, utilisant le Framework Django pour la gestion des URLs et des vues. Des modèles de machine Learning préalablement entraînés sont intégrés au système pour fournir des prédictions précises, tandis qu'une interface utilisateur conviviale permet aux utilisateurs de soumettre leurs données et de recevoir des retours.

En résumé, ce projet vise à combler le fossé entre la technologie et la santé en développant un système innovant de diagnostic médical assisté par le Machine Learning, offrant aux utilisateurs un moyen efficace de surveiller leur santé.

Chapitre 2 : Modélisation et Conception technique du projet

I. Introduction

Ce chapitre se concentre sur l'analyse et la conception de notre site web de prédiction de maladies. Nous explorerons les différentes phases de l'analyse et de la conception du projet, ainsi que les technologies du Machine Learning pour sa mise en œuvre.

II. Modélisation UML :

Le langage UML (Unified Modeling Language) est constitué de diagrammes intégrés utilisés pour la représentation visuelle des états et des processus dans un système. Le langage de modélisation peut servir de modèle pour un projet et garantir une architecture d'information structurée.

Dans le cadre de notre projet de prédiction de maladies, nous avons utilisé le diagramme de cas d'utilisation et le diagramme de séquences pour mieux comprendre les besoins et les exigences du système.

1. Diagramme des cas d'utilisation :

Le diagramme de cas d'utilisation joue un rôle essentiel dans la définition des fonctionnalités et des actions disponibles pour les utilisateurs sur notre site de prédiction de maladies. Il offre une vue d'ensemble claire et intuitive des différentes interactions possibles entre les utilisateurs et le système. En identifiant les acteurs principaux et en décrivant leurs objectifs et leurs actions dans le cadre du système, le diagramme de cas d'utilisation permet de guider efficacement le processus de conception et de développement du site.




Figure 5 : Diagramme de cas d'utilisation pour le patient

2. Diagramme de séquences :

Un diagramme de séquences est un type de diagramme de modélisation utilisé dans l'ingénierie logicielle et l'analyse des systèmes pour représenter la séquence d'interactions entre différents objets ou composants d'un système au fil du temps. Il met en évidence la manière dont ces objets communiquent entre eux dans un scénario donné.




Figure 6 : Diagramme de séquences

III. Schéma Générale du projet :




Figure 7 : Schéma représentatif du projet

IV. Les modèles utilisés :

1.Modèle séquentiel :

Les modèles séquentiels utilisés pour prédire le diabète et les maladies cardiovasculaires sont des réseaux de neurones artificiels organisés de manière linéaire, avec des couches empilées les unes sur les autres. Ces modèles utilisent des ensembles de données médicales pour estimer les risques de ces maladies chez les patients en analysant les différentes caractéristiques des données.




Figure 8 : Schéma du Modèle séquentiel

Pour expliquer en détail l'architecture des modèles séquentiels utilisés pour la prédiction du diabète et des maladies cardiovasculaires, on va décomposer chaque modèle en termes de couches, de neurones et de fonctions d'activation.

1.1 Modèle Séquentiel pour la Prédiction du Diabète :


Architecture du Modèle :

1. **Couche d'Entrée** : Cette couche est définie avec une forme d'entrée de (8,), ce qui signifie qu'elle attend des données d'entrée avec 8 caractéristiques.
2. **Couche Dense (16 Neurones)** : La première couche dense contient 16 neurones, et elle utilise une fonction d'activation ReLU (Rectified Linear Unit), qui est couramment utilisée pour les couches cachées de réseaux de neurones.
3. **Couche Dense (8 Neurones)** : La deuxième couche dense contient 8 neurones, également activés par la fonction ReLU.
4. **Couche de Sortie (1 Neurone)** : La dernière couche est une couche dense avec 1 neurone, activée par la fonction d'activation sigmoid. Cette fonction est souvent utilisée pour la classification binaire car elle produit une sortie entre 0 et 1, interprétable comme la probabilité de la classe positive.

Compilation et Entraînement du Modèle :

- Le modèle est compilé avec l'optimiseur Adam et la fonction de perte BinaryCrossentropy, spécifiquement conçue pour les tâches de classification binaire.
- Pendant l'entraînement, le modèle est ajusté aux données d'entraînement (X_train et y_train) pendant **1000 epochs**.

1.2 Evaluation du modèle :



```
18/18 ————— 0s 1ms/step
precision recall f1-score support
0 0.90 0.97 0.93 367
1 0.93 0.80 0.86 187

accuracy 0.91 554
macro avg 0.91 0.88 0.90 554
weighted avg 0.91 0.91 0.91 554

[[355 12]
 [ 38 149]]
Accuracy: 0.9097472924187726
Precision: 0.9254658385093167
Recall: 0.7967914438502673
F1 Score: 0.8563218390804598
```

Figure 9 : Evaluation de prédiction du diabète

1.3 Modèle Séquentiel pour la Prédiction des Maladies Cardiovasculaires :

Architecture du Modèle :

1. **Couche d'Entrée** : Cette couche est définie avec une forme d'entrée de (13,), ce qui signifie qu'elle attend des données d'entrée avec 13 caractéristiques.
2. **Couche Dense (26 Neurones)** : La première couche dense contient 26 neurones, activés par la fonction ReLU.
3. **Couche Dense (13 Neurones)** : La deuxième couche dense contient 13 neurones, également activés par la fonction ReLU.
4. **Couche Dense (26 Neurones)** : Une autre couche dense avec 26 neurones, cette fois activés par la fonction softmax. La fonction softmax est utilisée dans les tâches de classification multiclasse pour produire des probabilités normalisées pour chaque classe.
5. **Couche Dense (13 Neurones)** : Une deuxième couche dense avec 13 neurones, activés par la fonction softmax.
6. **Couche de Sortie (1 Neurone)** : Comme dans le modèle précédent, la couche de sortie est une couche dense avec 1 neurone, activée par la fonction sigmoid.

Compilation et Entraînement du Modèle :

- Le modèle est compilé de la même manière que le précédent.
- Pendant l'entraînement, le modèle est ajusté aux données d'entraînement pendant 1100 epochs.

1.4 Evaluation du modèle :

```

7/7 0s 6ms/step
precision recall f1-score support
0 0.93 0.97 0.95 102
1 0.97 0.92 0.95 103

accuracy 0.95 205
macro avg 0.95 0.95 0.95 205
weighted avg 0.95 0.95 0.95 205

[[99 3]
 [ 8 95]]
Accuracy: 0.9463414634146341
Precision: 0.9693877551020408
Recall: 0.9223300970873787
F1 Score: 0.9452736318407962

```

Figure 10 : Evaluation de prédiction du diabète

1.5 Comparaison des modèles :

Nous avons réalisé une comparaison entre trois modèles de machine Learning pour prédire le diabète et les maladies cardiovasculaires. Nous avons évalué trois modèles : le modèle séquentiel, la régression logistique et le SVM (Support Vector Machine).

Chaque modèle a été évalué en termes d'accuracy, de précision, de rappel (recall) et de score F1. Les résultats de cette comparaison sont présentés dans les deux tableaux ci-dessous :

Modèle	Accuracy	Précision	Recall	F1 Score
Séquentiel	0.90	0.92	0.79	0.85
Régression Logistique	0.78	0.71	0.59	0.65
SVM	0.78	0.71	0.61	0.66

Tableau I : Comparaison des modèles pour la prédiction du diabète

Les mêmes modèles ont été évalués pour la prédiction des maladies cardiovasculaires :

Modèle	Accuracy	Précision	Recall	F1 Score
Séquentiel	0.94	0.96	0.92	0.94
Régression Logistique	0.78	0.74	0.87	0.80
SVM	0.80	0.75	0.90	0.82

Tableau II : Comparaison des modèles pour la prédiction des maladies cardio

Après avoir examiné en détail les performances de chaque modèle pour la prédiction du diabète et des maladies cardiovasculaires, il est clair que le modèle séquentiel se distingue en termes d'accuracy, de précision, de rappel et de score F1 pour les deux tâches de prédiction. En conséquence, nous avons sélectionné **le modèle séquentiel** comme le plus approprié pour notre application de prédiction médicale.

1.6 Augmentation de notre Dataset pour une amélioration des modèles :

Dans le cadre de notre projet, afin d'améliorer la performance de nos modèles de prédiction du diabète et des maladies cardiovasculaires, nous avons pris des mesures pour enrichir notre jeu de données initial.

Plus précisément, nous avons augmenté la taille de notre ensemble de données en collectant davantage de données pertinentes auprès de sources fiables et diverses. Cette augmentation de la taille du Dataset a permis à nos modèles d'apprentissage automatique d'acquérir une meilleure capacité de généralisation en exposant le réseau à une plus grande variété de cas et de scénarios potentiels.

Par conséquent, les performances des modèles ont été améliorées, comme en témoignent les résultats de précision, de rappel et de score F1 plus élevés, ainsi qu'une augmentation globale de l'accuracy observée dans nos évaluations. En fin de compte, cette approche a renforcé la fiabilité et la validité de nos modèles séquentiels pour la prédiction médicale, consolidant ainsi leur statut comme choix privilégié pour notre application spécifique.

2. Modèle VGG16 :

Il s'agit d'un réseau de neurones convolutifs (CNN) utilisé spécifiquement pour la détection de la pneumonie à partir d'images radiographiques thoraciques. Son architecture comprend plusieurs couches de convolutions et de max-pooling, ce qui permet une extraction efficace des caractéristiques visuelles des images. Entraîné sur des ensembles de données appropriés, le modèle VGG16 peut contribuer au diagnostic de la pneumonie avec une précision significative. Cependant, ses performances peuvent être influencées par des facteurs tels que la qualité des images et la taille de l'ensemble de données.




Figure 11 : Architecture VGG16

2.1 Structure VGG16 :

a) Couche d'Entrée :

Cette couche est la première couche du modèle et reçoit les images en entrée. Dans le cas de VGG16, les images en entrée doivent avoir une taille de 224x224 pixels et 3 canaux de couleur (RVB).

b) Couches Convolutionnelles :

VGG16 comprend 13 couches convolutionnelles, chacune suivie d'une fonction d'activation ReLU. Ces couches sont responsables de l'extraction de caractéristiques des images en entrée à différentes échelles et niveaux d'abstraction.

c) Couches de Pooling :

Après chaque groupe de deux couches convolutionnelles, une couche de pooling max est utilisée pour réduire la dimension spatiale des caractéristiques extraites tout en préservant les caractéristiques les plus importantes.

d) Couches Fully Connected (Dense) :

Après les couches de convolution et de pooling, VGG16 comprend trois couches fully connected (Dense) avec des activations ReLU. Ces couches sont responsables de la classification finale en utilisant les caractéristiques extraites précédemment.

e) Couche de Sortie :

La couche de sortie est une couche fully connected (Dense) avec une activation softmax qui produit les probabilités de chaque classe de sortie. Dans le cas de VGG16 pré-entraîné sur ImageNet, il y a 1000 classes de sortie correspondant à différentes catégories d'objets.

f) Architecture de l'Empilement :

Les couches convolutionnelles et fully connected de VGG16 sont empilées de manière séquentielle avec les couches convolutionnelles au début, suivies des couches fully connected. Cette architecture en profondeur permet au modèle d'apprendre des représentations hiérarchiques complexes des données.

2.2 Modèle VGG16 pour la prédiction de la Pneumonie :

Dans notre projet , le modèle utilisé est basé sur l'architecture VGG16 pré-entraînée, avec quelques couches supplémentaires ajoutées pour l'adaptation à la tâche spécifique de détection de la pneumonie à partir d'images radiographiques thoraciques. Voici une description détaillée de l'architecture du modèle, ainsi que des détails sur la taille des données, le pourcentage de données de test, les époques et la taille du lot :

1. Architecture du modèle :

- **Couche d'Entrée** : La première couche du modèle, prenant en entrée des images de taille 224x224 pixels avec 3 canaux de couleur (RGB).
- **Couches Convolutionnelles** : il comprend 13 couches convolutionnelles avec des fonctions d'activation ReLU, responsables de l'extraction de caractéristiques des images.
- **Couches de Pooling** : Des couches de pooling max sont utilisées après chaque groupe de deux couches convolutionnelles pour réduire la dimension spatiale des caractéristiques extraites.
- **Couches Fully Connected (Dense)** : Trois couches fully connected sont ajoutées après les couches de convolution et de pooling, avec des activations ReLU, pour la classification finale.
- **Couche de Sortie** : La couche de sortie est une couche fully connected avec une activation softmax, produisant les probabilités de chaque classe de sortie (pneumonie ou non).
- **Architecture de l'Empilement** : Les couches convolutionnelles et fully connected sont empilées de manière séquentielle pour permettre au modèle d'apprendre des représentations hiérarchiques complexes des données.

2. Taille des données :

Les données utilisées pour l'entraînement du modèle de détection de la pneumonie sont organisées en trois dossiers distincts : test, validation et entraînement. Chaque dossier contient des sous-dossiers pour les cas normaux et de pneumonie. Les images sont redimensionnées à 224x224 pixels pour correspondre à l'entrée du modèle VGG16. Dans le dossier d'entraînement, il y a 1341 images normales et 3875 images de pneumonie. Le dossier de test contient 243 images normales et 390 images de pneumonie, tandis que le dossier de validation contient 8 images pour chaque classe. Cette organisation assure une représentation équilibrée des cas normaux et de pneumonie pour un apprentissage efficace du modèle.

3. Pourcentage de données de test :

Les données sont divisées en ensembles d'entraînement, de validation et de test. Cependant, le code fourni ne spécifie pas explicitement le pourcentage des données de test. Cela dépend de la manière dont les répertoires d'entraînement, de validation et de test sont structurés.

4. Époques :

Dans le code fourni, le modèle est entraîné pour une seule époque. Cependant, en pratique, le nombre d'époques devrait être ajusté pour obtenir de meilleures performances. Une valeur typique pourrait être de plusieurs dizaines d'époques, en fonction de la complexité du problème et de la taille du jeu de données.

5. Taille du lot (batch size) :

La taille du lot utilisée pour l'entraînement du modèle est définie à 10 dans le code fourni. Cela signifie que le modèle est mis à jour après avoir vu 10 échantillons d'entraînement. La taille du lot peut également être ajustée en fonction des ressources matérielles disponibles et de la taille du jeu de données.

En résumé, le modèle utilise l'architecture VGG16 avec quelques modifications pour la tâche de détection de la pneumonie. Les données sont prétraitées pour correspondre à la taille d'entrée requise par le modèle. L'entraînement est effectué sur un seul lot d'échantillons avec une époque.

20/20			359s	18s/step	
	precision		recall	f1-score	support
NORMAL	0.93	0.88	0.90		244
PNEUMONIA	0.93	0.96	0.94		390
accuracy				0.93	634
macro avg	0.93	0.92	0.92		634
weighted avg	0.93	0.93	0.93		634
Confusion Matrix:					
[[214 30]					
[16 374]]					

Figure 12 : Evaluation du modèle VGG16

3. Le Chatbot médical :

Le chatbot intégré dans notre projet est un système automatisé de traitement du langage naturel (NLP) conçu pour interagir avec les utilisateurs via des conversations textuelles. Il est capable de comprendre et de répondre à des requêtes basées sur un ensemble de données d'entraînement étiqueté.

Notre chatbot utilise des techniques de NLP pour traiter les messages entrants et un modèle de réseau de neurones à propagation avant pour la classification des messages.

3.1 Fonctionnement

Entraînement du modèle : Le chatbot est entraîné sur un ensemble de données étiqueté qui comprend des messages textuels associés à des catégories. Chaque message est représenté sous forme de vecteur Bag of Words, où chaque élément du vecteur correspond à un mot unique dans le corpus.

L'idée derrière Bag of Words est de représenter chaque message (ou phrase) comme un vecteur où chaque élément du vecteur correspond à un mot unique dans le corpus de formation, et la valeur de chaque élément indique la présence ou l'absence de ce mot dans le message donné.

<u>Training Data</u>								
<u>bag of words</u>								
<u>all words</u>								
["Hi", "How", "are", "you", "bye", "see", "later"]								
"Hi"	→	[1,	0,	0,	0,	0,	0]	0 (greeting)
"How are you?"	→	[0,	1,	1,	1,	0,	0]	
"Bye"	→	[0,	0,	0,	0,	1,	0]	1 (goodbye)
"See you later"	→	[0,	0,	0,	1,	0,	1]	
				X		y		

Figure 13 : Exemple d'entraînement d'un message textuel

Construction du modèle : Un modèle de réseau de neurones à propagation avant est construit pour la classification des messages. Le modèle comprend une couche d'entrée correspondant à la taille du vecteur Bag of Words, une ou plusieurs couches cachées et une couche de sortie avec une fonction d'activation softmax pour la classification des messages dans les différentes catégories.





Figure 14 : L'architecture du modèle de réseaux de neurones à propagation avant .

Prédiction des messages : Lorsqu'un nouveau message est reçu, il est prétraité à l'aide de techniques de NLP telles que la tokenization et le stemming pour le convertir en une

représentation numérique. Ensuite, le modèle de réseau de neurones est utilisé pour prédire la catégorie du message, qui est renvoyée à l'utilisateur comme réponse.

3.2 Comment on a utilisé NLP ?


- **Tokenization** : Division d'une chaîne de caractères en unités significatives telles que des mots, des caractères de ponctuation, des nombres, etc.



```
"aren't you happy with so much money?"  
→ [ "are", "n't", "you", "happy", "with", "so", "much", "money", "?" ]
```

Figure 15 : Exemple de Tokenization

- **Stemming** : Génération de la forme racine des mots en utilisant des heuristiques simples pour enlever les suffixes et préfixes.



```
"organize", "organizes", "organizing"  
→ [ "organ", "organ", "organ" ]
```

Figure 16 : Exemple de Stemming

- **Pipeline de prétraitement NP** : Un pipeline de prétraitement est utilisé pour traiter les messages textuels avant de les représenter sous forme de vecteurs Bag of Words. Cela comprend la tokenization, la conversion en minuscules, le stemming et l'exclusion des caractères de ponctuation.




Figure 17 : Traitement d'un message avant de le représenter sous forme de vecteurs Bag of Words

Le Chatbot utilise une combinaison de techniques de NLP et de modélisation de réseau de neurones pour comprendre et répondre aux requêtes textuelles des utilisateurs. Grâce à son architecture robuste et à son entraînement sur un ensemble de données étiqueté, le chatbot peut fournir des réponses précises et pertinentes aux utilisateurs, améliorant ainsi l'expérience globale de l'utilisateur

4. Conclusion

Ce chapitre détailler l'utilisation de ces langages, outils et modèles dans notre projet, ainsi que leur rôle dans le développement de l'application médicale.

Chapitre 3 : Technologies Utilisées

I. Introduction

Ce chapitre se focalise sur les langages de programmation, les outils utilisés dans la réalisation de notre projet. Nous explorerons les technologies qui ont été essentielles pour le développement de l'application.

II. Les langages et les outils utilisés

Django :

Django est un Framework Web Python de haut niveau utilisé pour développer rapidement et facilement des applications Web. Il suit le modèle architectural Modèle-Vue-Contrôleur (MVC) et encourage l'utilisation de code réutilisable en suivant le principe « Ne vous répétez pas » (DRY).



NLTK (Natural Language Toolkit) :

NLTK est une bibliothèque Python dédiée au traitement automatique du langage naturel, offrant des fonctionnalités avancées telles que l'analyse syntaxique, la lemmatization, la tokenization et la classification de texte, utilisée dans la recherche et le développement d'applications de NLP.

TensorFlow :

Est une bibliothèque open-source en Python développée par Google, spécialisée dans le Machine Learning et le Deep Learning, offrant des outils pour la création, l'entraînement et le déploiement de modèles d'apprentissage automatique sur diverses plates-formes. TensorFlow est largement utilisé dans la recherche et l'industrie pour des applications telles que la reconnaissance d'images, la traduction automatique et le traitement du langage naturel.



HTML(HyperText Markup Language) :




Est le Langage de Balisage Hypertexte utilisé pour créer et structurer le contenu des pages web. Il utilise des balises pour définir la structure et le format du contenu, permettant ainsi de présenter du texte, des images, des liens et d'autres éléments sur les sites web. HTML est la base fondamentale de la plupart des pages web et assure leur accessibilité et leur compatibilité sur différents appareils et navigateurs.

CSS (Cascading Style Sheets) :

Est un langage informatique utilisé pour définir la présentation visuelle des pages web écrites en HTML. Grâce aux feuilles de style, on peut contrôler les couleurs, les polices, les marges, les mises en page et d'autres aspects de la mise en forme des éléments HTML. CSS permet de séparer la mise en forme du contenu, facilitant ainsi la conception de sites web attrayants et adaptatifs sur différents appareils.



JavaScript :



Est un langage de programmation de script utilisé pour rendre les pages web interactives et dynamiques. Il permet d'ajouter des fonctionnalités interactives telles que la validation de formulaires, les animations et les interactions en temps réel avec les utilisateurs. JavaScript est essentiel pour améliorer l'expérience utilisateur sur les sites web et joue un rôle important dans le développement d'applications web avancées.

Bootstrap:

Bootstrap est un framework de développement web gratuit et open source. Il permet de créer des sites web et des applications web réactives avec des composants et des styles prêts à l'emploi. Grâce à Bootstrap, les développeurs peuvent concevoir rapidement des interfaces modernes et adaptatives pour une expérience utilisateur optimale sur différents appareils. C'est l'un des frameworks les plus populaires pour le développement web en raison de sa simplicité et de sa polyvalence.






SQL :

SQL (Structured Query Language) est un langage de programmation utilisé pour gérer les bases de données relationnelles. Il permet de créer, lire, mettre à jour et supprimer des données, offrant des commandes standardisées pour interagir avec les systèmes de gestion de bases de données.

XAMPP :

XAMPP est un logiciel open-source facilitant la création d'un environnement de développement web local en regroupant Apache, MySQL, PHP et Perl. Il permet aux développeurs de concevoir, tester et déboguer des sites web sans nécessiter de connexion internet.



Visual Studio Code :

Visual Studio Code est un éditeur de code extensible développé par Microsoft pour Windows, Linux et macOS. Les fonctionnalités incluent la prise en charge du débogage, la mise en évidence de la syntaxe, la complétion intelligente du code, les snippets, la refactorisation du code et Git intégrer.

Chapitre 4 : Implémentation du Projet

Page d'accueil :

La page d'accueil offre aux utilisateurs un premier aperçu du projet, mettant en évidence son objectif principal. En outre, les utilisateurs peuvent apercevoir plusieurs icônes représentant les autres pages, ce qui facilite leur navigation et leur compréhension de la structure globale du projet.



Figure 18 : Page d'accueil / Partie 1



Figure 19 : Page d'accueil / Partie 2

Page d'inscription :

La page d'inscription est l'endroit où les utilisateurs s'inscriront pour accéder aux fonctionnalités de prédiction des maladies. Elle comprend des champs pour collecter les informations nécessaires des utilisateurs, comme leur nom, leur adresse e-mail et leur mot de passe.




Figure 20 : Page d'authentification

Page de connexion :

La page de connexion est destinée aux utilisateurs déjà inscrits pour accéder à leur compte. Elle offre un moyen rapide et sécurisé pour les utilisateurs de se connecter en utilisant leurs identifiants.




Figure 21 : Page de connexion

Le cas d'oubli de mot de passe :

La fonction de mot de passe oublié est une fonctionnalité de récupération importante qui permet aux utilisateurs d'obtenir un nouveau mot de passe s'ils l'ont oublié. Cette page guidera les utilisateurs tout au long du processus de réinitialisation du mot de passe.




Figure 22 : Oubli de Mot de Passe

Création d'un nouveau mot de passe :

La page de création d'un nouveau mot de passe permet aux utilisateurs de choisir un nouveau mot de passe sécurisé en cas de besoin. Elle garantit la sécurité des comptes des utilisateurs.



Figure 23 : Changement de mot de passe

Page de prédiction du diabète:

La page de prédiction du diabète permet aux utilisateurs de saisir les informations nécessaires pour obtenir une prédiction de leur risque de diabète. Les résultats sont présentés de manière claire, avec des informations sur les facteurs de risque et les mesures préventives.




Figure 24 : Page de Prédiction du diabète




Figure 25 : Résultat de Prédiction

Page de prédiction de la pneumonie:

La page de prédiction de la pneumonie permet aux utilisateurs de télécharger des images radiographiques pour obtenir une prédiction de leur risque de contracter une pneumonie. Les résultats sont affichés de manière concise.



Figure 26 : Page de Prédiction de Pneumonie



Figure 27 : Résultat de prédiction

Page de prédiction des maladies:

La page de prédiction des maladies cardiovasculaires permet aux utilisateurs de saisir leurs données pour obtenir une estimation de leur risque de maladies cardiovasculaires. Les résultats sont présentés de manière claire, avec des recommandations pour améliorer la santé cardiovasculaire.

The screenshot shows a web browser window with the URL '127.0.0.1:8000/cardio/'. The page title is 'Prediction Cardiovascular'. On the left is a dark sidebar with icons for home, user, heart, and a back arrow. The main form contains the following fields:

- Âge : (text input)
- Sexe : (dropdown menu, currently showing 'Homme')
- Type de douleur thoracique : (dropdown menu, currently showing 'Absence de douleur')
- Pression artérielle au repos en mmHg : (text input)
- Cholestérol sérique en mg/dL : (text input)
- Glycémie à jeun : (dropdown menu, currently showing 'supérieur ou égal à 120 mg/dL')
- Résultats électrocardiographiques au repos : (dropdown menu, currently showing 'Normal')
- Fréquence cardiaque maximale atteinte (bpm) : (text input)
- Angine déclenchée par l'exercice : (dropdown menu, currently showing 'Absent')
- Pente du segment ST à l'exercice maximal : (dropdown menu, currently showing 'Ascendante')
- dépression induite par l'exercice par rapport au repos (valuer entre 0 et 6.2) : (text input)
- Nombre de gros vaisseaux colorés par fluoroscopie : (dropdown menu, currently showing 'Aucun')
- Thalassemia : (dropdown menu, currently showing 'normal')
- ☐ Enregistrer les données

Figure 28 : Page de Prediction Heart-Disease

The screenshot shows a light blue box with the following text:

- patient User name : si7_boudans
- Age : 59
- prediction maladie : Vous n'êtes pas souffrez de Cardiovascular
- pourcentage de maladie est : 4.0%

Below the box, there is a faint, partially visible text: 'vous n'avez pas souffrez de Cardiovascular'.

Figure 29 : Résultat de Prédiction

Page de chatbot médical :

La page de chatbot médical offre aux utilisateurs la possibilité de poser des questions sur leur santé et les maladies prédites. Elle offre une interaction conviviale avec un assistant virtuel qui peut fournir des informations médicales et des conseils sur la base des données saisies par l'utilisateur.




Figure 30 : Chatbot

Conclusion Générale

La réalisation de ce projet de site web dédié à la prédiction des maladies représente une étape significative dans notre parcours académique. À travers ce rapport, nous avons mis en lumière l'importance croissante des sciences de données dans le domaine de la santé, ainsi que l'impact potentiellement révolutionnaire de l'intégration de la technologie dans la médecine.

En combinant des techniques avancées d'apprentissage automatique avec un chatbot interactif, notre plateforme offre une solution innovante pour prédire les maladies et fournir un support en temps réel aux utilisateurs. Cette approche non seulement améliore l'accessibilité aux services de santé en ligne, mais elle ouvre également de nouvelles perspectives pour l'amélioration des diagnostics préventifs et la gestion des maladies chroniques.

Au cours de ce projet, nous avons acquis des compétences précieuses en matière d'analyse de données médicales, de développement web et d'intégration de technologies interactives. Nous sommes convaincus que ces compétences seront précieuses dans notre future carrière professionnelle et qu'elles contribueront à relever les défis complexes du domaine de la santé.

Nous sommes également conscients que ce projet n'est qu'une première étape et qu'il reste encore beaucoup à explorer et à améliorer dans le domaine de la santé numérique. Nous espérons que ce rapport servira d'inspiration à d'autres chercheurs et développeurs pour poursuivre l'innovation dans ce domaine crucial.

Enfin, nous tenons à exprimer notre gratitude envers notre encadrant, nos enseignants, et toutes les personnes qui ont contribué à la réalisation de ce projet. Leur soutien et leurs conseils ont été essentiels à notre réussite.

En conclusion, nous sommes fiers du travail accompli et nous sommes optimistes quant à l'impact positif que notre projet pourrait avoir sur l'avenir des soins de santé. Nous sommes impatients de voir comment cette technologie continuera à évoluer et à transformer le paysage médical dans les années à venir.

Références Bibliographiques

<https://www.djangoproject.com/star>

Dataset Diabète : <https://www.kaggle.com/datasets/nanditapore/healthcare-diabetes>

Dataset Heart-Disease : <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

Dataset Pneumonie : <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>

<https://youtu.be/t933Gh5fNrc?si=57SWbT71vdvpWZC0>

<https://staruml.io/>

<https://lucid.app/>